

本文解决ood问题的思想是建模domain的特征统计量的不确定性：不把这些特征统计量当成确定值，而是假设它们服从多元高斯分布，即统计量的均值和标准差分别服从潜在的高斯分布 $\mathcal{N}(\mu, \Sigma_\mu)$ 和 $\mathcal{N}(\sigma, \Sigma_\sigma)$ ，且该潜在高斯分布的中心是在各统计量处，也就是说 $\mu$ 和 $\sigma$ 是容易得到的，取统计量即可。关键在于对 $\Sigma_\mu$ 和 $\Sigma_\sigma$ 的建模，这两个统计量的方差体现了数据分布的不确定性，即domain shift的方向和强度。**因此本文的思路大致可以理解为通过建模分布的分布来刻画ood数据。**据此提出了一种新的data augmentation的方法，通过对数据统计量的重参数化技巧，建模在domain shift条件下，统计特征的不确定性。然后通过得到的概率模型对数据进行重新采样，实现data augmentation，以增强网络的泛化能力。

### 具体方法：

给定 $x \in R^{B \times C \times H \times W}$ ， $B$ 是batch大小， $C$ 是channel数（为什么是分channel而不是domain？），首先计算channel wise的均值 $\mu \in R^{B \times C}$ 和方差 $\sigma^2 \in R^{B \times C}$ ： $\mu(x) = \frac{1}{HM} \sum_{h=1}^H \sum_{w=1}^W x_{b,c,h,w}$   
 $\sigma^2(x) = \frac{1}{HW} \sum_{h=1}^H \sum_{w=1}^W (x_{b,c,h,w} - \mu(x))^2$

得到的只是基于训练数据的统计量，或者可以理解为特征变化的中心。而变化的幅度，即 $\Sigma_\mu$ 和 $\Sigma_\sigma$ 要靠下面的方法确定：

提出了一种非参数化的方法，即对batch内的数据算方差： $\Sigma_\mu^2 = \frac{1}{B} \sum_{b=1}^B (\mu(x) - E_b[\mu(x)])^2$   
 $\Sigma_\sigma^2 = \frac{1}{B} \sum_{b=1}^B (\sigma(x) - E_b[\sigma(x)])^2$

得到的 $\Sigma_\mu \in R^C$ 和 $\Sigma_\sigma \in R^C$ 是对各channel的均值和标准差的不确定性的估计。

之后可以用重参数化技巧建模数据均值和标准差的分布：

$$\beta(x) = \mu(x) + \epsilon_\mu \Sigma_\mu(x), \quad \epsilon_\mu \sim \mathcal{N}(0, 1) \quad \gamma(x) = \sigma(x) + \epsilon_\sigma \Sigma_\sigma(x), \quad \epsilon_\sigma \sim \mathcal{N}(0, 1)$$

然后抽样得到增强后的数据 $\hat{x} = \gamma(x) \times \frac{x - \mu(x)}{\sigma(x)} + \beta(x)$ 。实际中，以 $p$ 的概率执行如上的数据增强。这种操作可以灵活地加入网络的任何位置。